

پروژه نهایی یادگیری ماشین در زیست پزشکی

طبقه‌بندی تومورهای مغزی با استفاده از تصاویر MRI

محمد احدزاده - 40133002

تابستان 1404

فهرست	
2	چکیده
2	مقدمه
3	مجموعه داده و پیش‌پردازش
4	روش‌شناسی مدل‌های کلاسیک
4	استخراج ویژگی با HOG
4	کاهش ابعاد با PCA
5	آموزش و ارزیابی مدل‌ها
5	روش‌شناسی مدل یادگیری عمیق
5	معماری شبکه
5	فرآیند آموزش
6	نتایج و بحث
6	عملکرد مدل‌های کلاسیک
7	عملکرد مدل یادگیری عمیق
9	مقایسه نهایی مدل‌ها
10	نتیجه‌گیری
11	منابع

چکیده

تشخیص دقیق و به موقع تومورهای مغزی یکی از چالش‌های اساسی در حوزه پزشکی است که می‌تواند به طور قابل توجهی بر روند درمان و کیفیت زندگی بیماران تأثیر بگذارد. با پیشرفت‌های اخیر در زمینه هوش مصنوعی، استفاده از الگوریتم‌های یادگیری ماشین و یادگیری عمیق برای تحلیل تصاویر پزشکی مانند MRI به یک رویکرد امیدوارکننده تبدیل شده است. هدف اصلی این پروژه، توسعه و ارزیابی یک مدل تشخیصی خودکار برای طبقه‌بندی انواع مختلف تومورهای مغزی است. در این راستا، از یک مجموعه داده جامع شامل تصاویر MRI از چهار کلاس مختلف یعنی تومور گلیوما، تومور مننژیوما، تومور هیپوفیز و نمونه‌های سالم بدون تومور استفاده شده است. در این گزارش، دو رویکرد متفاوت مورد بررسی قرار گرفته‌اند. رویکرد اول مبتنی بر الگوریتم‌های کلاسیک یادگیری ماشین است که در آن ابتدا با استفاده از روش Histogram of Oriented Gradients یا به اختصار HOG از تصاویر استخراج ویژگی شده و سپس ابعاد ویژگی‌ها با روش Principal Component Analysis کاهش می‌یابد. در ادامه، مدل‌های مختلفی مانند Support Vector Machine و Random Forest بر روی این ویژگی‌ها آموزش داده می‌شوند. رویکرد دوم، استفاده از یک مدل Convolutional Neural Network یا CNN است که قادر است به صورت مستقیم و خودکار ویژگی‌های لازم را از تصاویر یاد بگیرد. نتایج به دست آمده نشان می‌دهد که مدل CNN با دستیابی به دقت نزدیک به ۹۸ درصد، عملکرد به مراتب بهتری نسبت به روش‌های کلاسیک داشته و پتانسیل بالایی برای استفاده در سیستم‌های تشخیص پزشکی دارد.

مقدمه

تومورهای مغزی به دلیل رشد غیرقابل کنترل سلول‌ها در مغز به وجود می‌آیند و به دو دسته خوش‌خیم و بدخیم تقسیم می‌شوند. تشخیص نوع تومور برای انتخاب بهترین استراتژی درمانی از اهمیت حیاتی برخوردار است. روش‌های سنتی تشخیص معمولاً متکی بر تخصص رادیولوژیست‌ها برای تفسیر تصاویر MRI است که فرآیندی زمان‌بر و مستعد خطای انسانی است. بنابراین، توسعه سیستم‌های کامپیوتری هوشمند که بتوانند به عنوان یک ابزار کمکی در کنار متخصصان قرار گیرند، می‌تواند به افزایش دقت و سرعت تشخیص کمک شایانی کند. این پروژه با هدف ساخت و مقایسه مدل‌های تشخیصی مبتنی بر یادگیری ماشین و یادگیری عمیق برای طبقه‌بندی چهار حالت مختلف مغز از روی تصاویر MRI تعریف شده است.

مجموعه داده و پیش‌پردازش

در این پروژه از مجموعه داده Brain Tumor MRI Dataset که از پلتفرم Kaggle تهیه شده، استفاده گردیده است. این دیتاست شامل ۷۰۲۳ تصویر MRI مغز است که در چهار کلاس دسته‌بندی شده‌اند: glioma، meningioma، pituitary و no tumor. توزیع داده‌ها در کلاس‌های مختلف تقریباً متوازن است که این امر به آموزش بهتر مدل‌ها و جلوگیری از سوگیری به سمت کلاس خاص کمک می‌کند.

برای آماده‌سازی داده‌ها جهت استفاده در مدل CNN، یک سری مراحل پیش‌پردازش و data augmentation انجام شد. تمامی تصاویر به ابعاد ۲۲۴ در ۲۲۴ پیکسل تغییر اندازه داده شدند تا ورودی یکسانی برای شبکه عصبی فراهم شود. سپس، برای افزایش حجم داده‌های آموزشی و جلوگیری از بیش‌برازش، تکنیک‌های data augmentation مانند چرخش تصادفی، برگرداندن افقی و تغییرات جزئی در روشنایی و کنتراست تصاویر اعمال گردید. در نهایت، مقادیر پیکسل‌ها نرمال‌سازی شدند تا فرآیند یادگیری مدل پایدارتر شود. مجموعه داده به سه بخش اصلی تقسیم شد: ۸۵ درصد برای آموزش، ۱۵ درصد برای اعتبارسنجی در حین آموزش و یک مجموعه داده تست کاملاً مجزا برای ارزیابی نهایی مدل‌ها.




شکل ۱. توزیع کلاس‌ها در داده آموزش

روش‌شناسی مدل‌های کلاسیک

مدل‌های کلاسیک یادگیری ماشین برخلاف مدل‌های یادگیری عمیق نمی‌توانند مستقیماً با داده‌های خام تصویری کار کنند و نیازمند یک مرحله استخراج ویژگی هستند. در این مرحله، اطلاعات مهم و قابل تفسیر از تصویر به صورت یک بردار عددی استخراج می‌شود.

استخراج ویژگی با HOG

در این پروژه، از روش Histogram of Oriented Gradients برای استخراج ویژگی استفاده شد. این روش به طور موثری اطلاعات مربوط به شکل و بافت موجود در تصویر را از طریق محاسبه گرادیان و جهت‌گیری لبه‌ها ثبت می‌کند. تصویر زیر یک نمونه از تصویر ورودی و خروجی استخراج ویژگی HOG از آن را نمایش می‌دهد. همانطور که مشخص است، این روش توانسته است ساختارهای اصلی تومور و مجامه را به خوبی به صورت ویژگی‌های عددی نمایش دهد.



شکل 2. نمونه ای از تصویر ورودی و ویژگی HOG خروجی

کاهش ابعاد با PCA

بردار ویژگی استخراج شده توسط HOG ابعاد نسبتاً بالایی دارد که می‌تواند منجر به افزایش پیچیدگی محاسباتی و بیش‌برازش شود. برای حل این مشکل، از روش Principal Component Analysis استفاده شد تا ابعاد فضای ویژگی کاهش یابد. این روش با یافتن مؤلفه‌های اصلی که بیشترین واریانس داده‌ها را توصیف می‌کنند، ابعاد را کاهش می‌دهد در حالی که بخش عمده‌ای از اطلاعات

اصلی حفظ می‌شود.

آموزش و ارزیابی مدل‌ها

پس از آماده‌سازی ویژگی‌ها، مجموعه‌ای از الگوریتم‌های طبقه‌بندی کلاسیک بر روی داده‌های آموزشی آموزش داده شدند. این الگوریتم‌ها شامل Logistic Regression، Linear Discriminant Analysis، Support Vector Machine بودند. علاوه بر این، یک مدل Ensemble از نوع Voting Classifier با ترکیب سه مدل برتر یعنی SVM، Random Forest و KNN ساخته شد تا از خرد جمعی آن‌ها برای رسیدن به دقت بالاتر استفاده شود.

روش‌شناسی مدل یادگیری عمیق

مزیت اصلی CNN‌ها توانایی آن‌ها در یادگیری خودکار ویژگی‌های سلسله‌مراتبی از تصاویر است. این شبکه‌ها با استفاده از لایه‌های کانولوشنی، فیلترهایی را یاد می‌گیرند که می‌توانند ویژگی‌های ساده مانند لبه‌ها و رنگ‌ها را در لایه‌های ابتدایی و ویژگی‌های پیچیده‌تر مانند اشکال و بافت‌ها را در لایه‌های عمیق‌تر شناسایی کنند.

معماری شبکه

معماری CNN طراحی شده در این پروژه شامل سه بلوک کانولوشنی متوالی است. هر بلوک از یک لایه Conv2d برای استخراج ویژگی، یک تابع فعال‌سازی ReLU برای افزودن غیرخطی بودن و یک لایه MaxPool2d برای کاهش ابعاد فضایی و افزایش مقاومت مدل به جابجایی‌های کوچک تشکیل شده است. پس از بخش استخراج ویژگی، یک بخش طبقه‌بند قرار دارد که از لایه‌های کاملاً متصل یا Fully Connected تشکیل شده است. این بخش شامل یک لایه Flatten برای تبدیل نقشه ویژگی‌های دو بعدی به یک بردار تک بعدی، یک لایه Linear با تابع فعال‌سازی ReLU و در نهایت یک لایه خروجی Linear با چهار نورون متناظر با چهار کلاس مسئله است. برای جلوگیری از بیش‌برازش، از یک لایه Dropout با نرخ ۰.۵ نیز در بخش طبقه‌بند استفاده شده است.

فرآیند آموزش

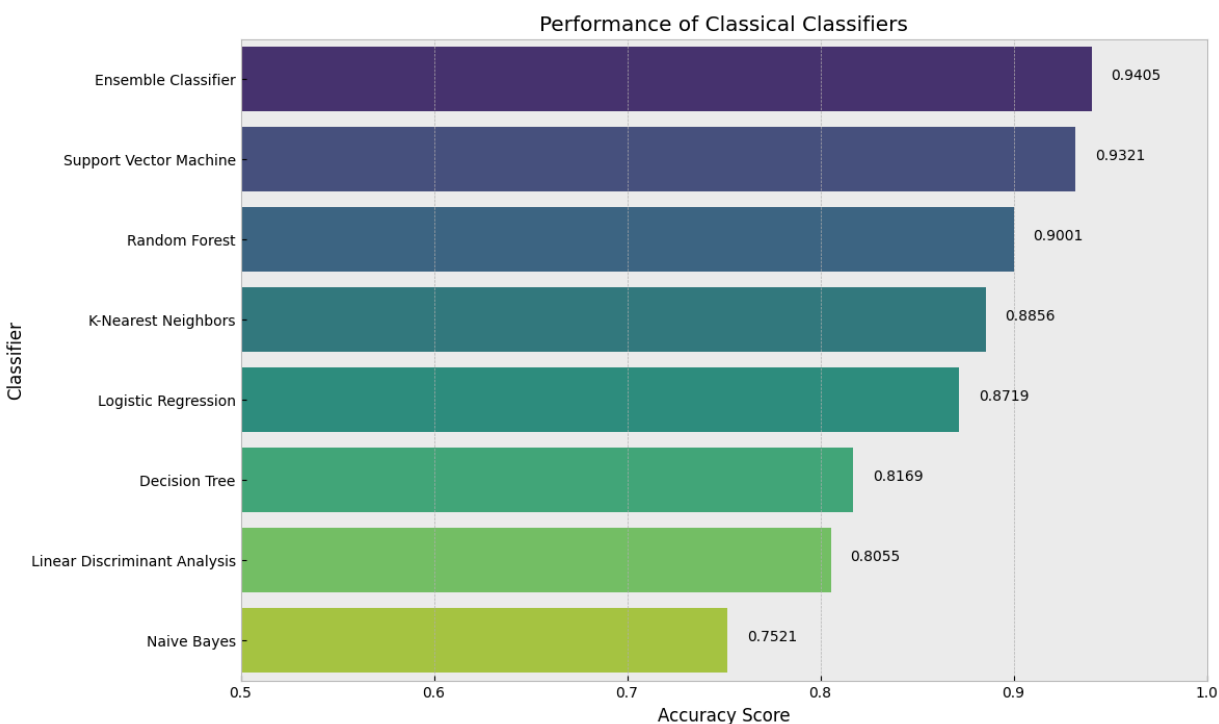
مدل CNN با استفاده از تابع هزینه CrossEntropyLoss و بهینه‌ساز Adam با نرخ یادگیری ۰.۰۰۱ به مدت ۳۰ epoch آموزش داده شد. در هر epoch، مدل بر روی داده‌های آموزشی یادگیری را انجام می‌داد و عملکرد آن بر روی داده‌های اعتبارسنجی ارزیابی می‌شد تا بهترین نسخه مدل که دارای بالاترین

دقت روی داده‌های اعتبارسنجی است، ذخیره شود.

نتایج و بحث

عملکرد مدل‌های کلاسیک

مدل‌های کلاسیک پس از آموزش بر روی ویژگی‌های استخراج شده با HOG و کاهش ابعاد یافته با PCA، بر روی مجموعه داده تست ارزیابی شدند. نمودار زیر دقت هر یک از این مدل‌ها را نمایش می‌دهد.

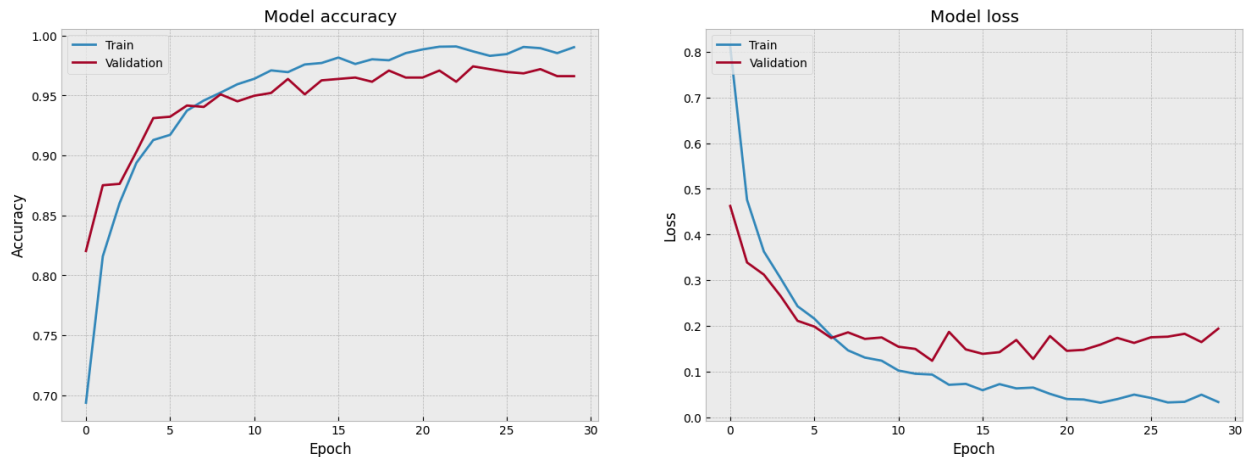


شکل 3. عملکرد مدل‌های طبقه‌بندی کلاسیک

همانطور که مشاهده می‌شود، مدل Ensemble Classifier با دستیابی به دقت حدود ۹۴ درصد، بهترین عملکرد را در میان روش‌های کلاسیک به خود اختصاص داده است. پس از آن، مدل Support Vector Machine با دقت ۹۳.۲ درصد و Random Forest با دقت ۹۰ درصد در رتبه‌های بعدی قرار دارند. این نتایج نشان می‌دهد که ترکیب ویژگی‌های HOG با مدل‌های قدرتمندی مانند SVM و Ensemble می‌تواند به نتایج قابل قبولی منجر شود.

عملکرد مدل یادگیری عمیق

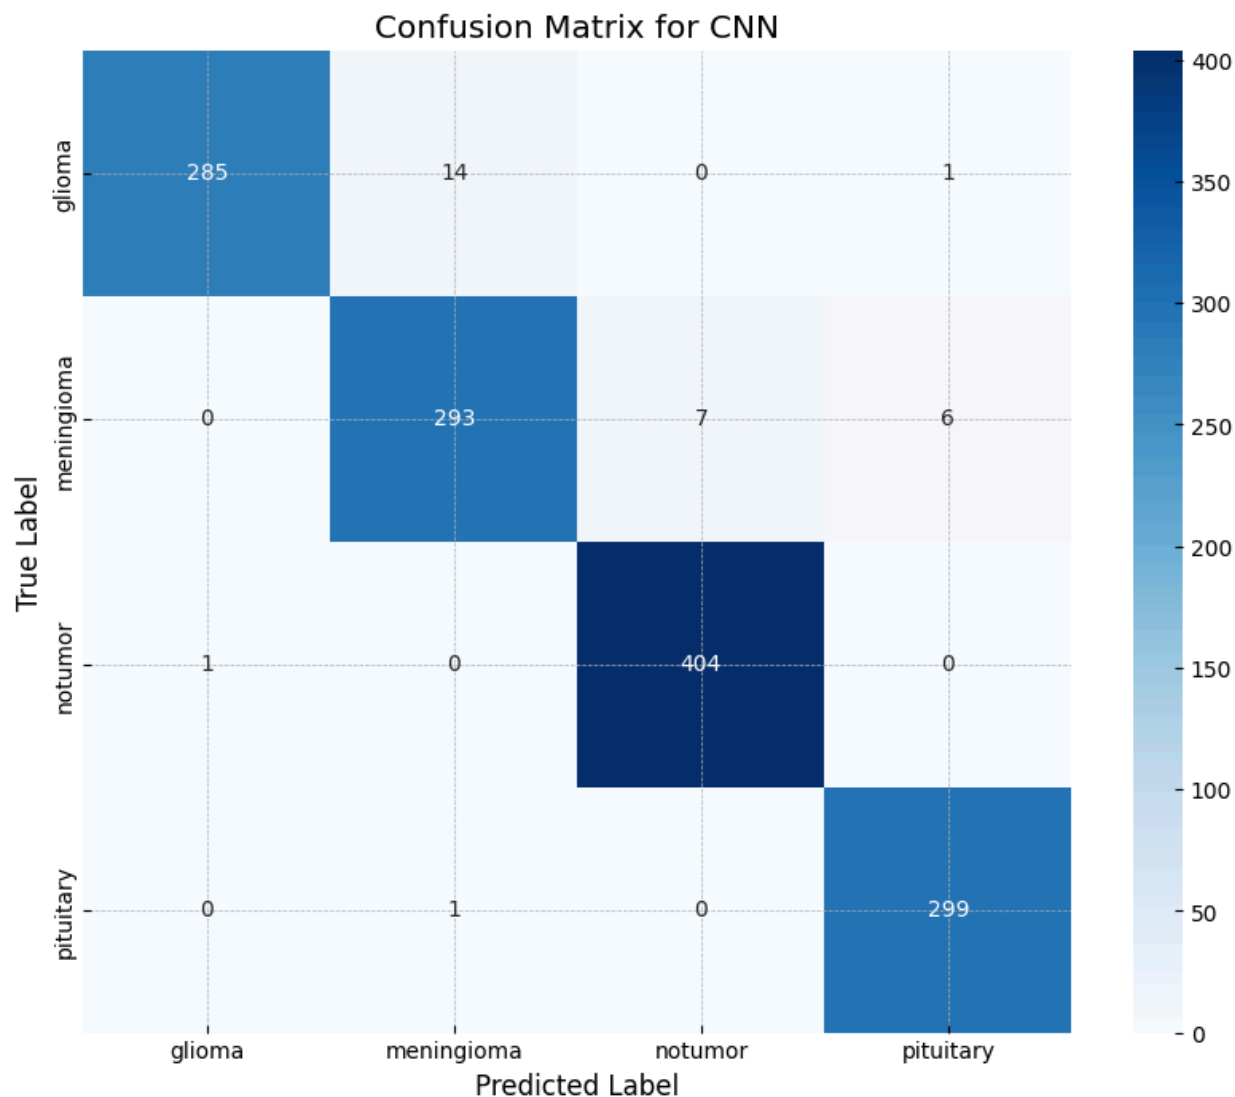
مدل CNN پس از طی epoch ۳۰ فرآیند آموزش، به نتایج بسیار خوبی دست یافت. نمودارهای زیر روند تغییرات دقت و loss را بر روی داده‌های آموزشی و اعتبارسنجی در طول زمان نشان می‌دهند.



شکل 4. نمودار فرآیند آموزش مدل CNN

این نمودارها نشان می‌دهند که مدل به خوبی همگرا شده است. دقت آموزشی و اعتبارسنجی هر دو به طور پیوسته افزایش یافته و loss آن‌ها کاهش پیدا کرده است. فاصله کم بین منحنی‌های آموزش و اعتبارسنجی نشان‌دهنده این است که مدل دچار بیش‌برازش شدید نشده و توانایی تعمیم‌پذیری خوبی دارد.

برای ارزیابی دقیق‌تر عملکرد مدل CNN، ماتریس درهم‌ریختگی یا Confusion Matrix آن بر روی داده‌های تست محاسبه شد.

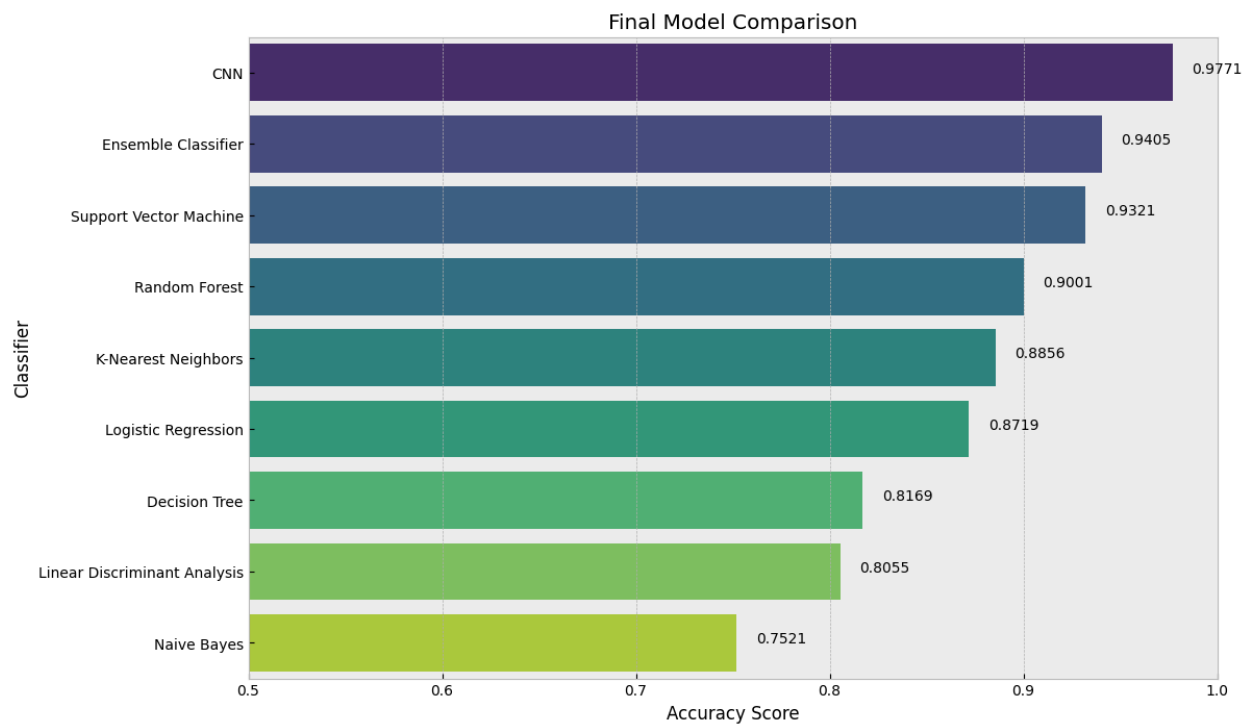


شکل 5. ماتریس درهم‌ریختگی مدل CNN

این ماتریس نشان می‌دهد که مدل در تشخیص کلاس no tumor و pituitary تقریباً بی‌نقص عمل کرده است. بیشترین خطا مربوط به تشخیص اشتباه تعداد کمی از نمونه‌های glioma به عنوان meningioma است که با توجه به شباهت‌های بصری این دو نوع تومور، قابل توجیه است. به طور کلی، اعداد روی قطر اصلی بسیار بزرگتر از سایر مقادیر هستند که نشان‌دهنده عملکرد فوق‌العاده مدل است. گزارش طبقه‌بندی نهایی نیز مقادیر بالای recall، precision، و f1-score را برای تمام کلاس‌ها تأیید می‌کند و دقت کلی مدل بر روی داده‌های تست ۹۷.۷۱ درصد محاسبه شد.

مقایسه نهایی مدل‌ها

در نهایت، برای مقایسه جامع بین بهترین مدل کلاسیک و مدل یادگیری عمیق، نمودار زیر ارائه شده است.



شکل 6. نمودار نهایی مقایسه عملکرد تمامی مدل‌ها

جدول 1. ارزیابی عملکرد تمامی مدل‌ها

Model	Accuracy	Precision	Recall	F1-Score
Classical Classifiers				
Logistic Regression	0.8719	0.87	0.87	0.87
Linear Discriminant Analysis	0.8055	0.80	0.81	0.80
K-Nearest Neighbors	0.8856	0.89	0.89	0.88

Decision Tree	0.8169	0.82	0.82	0.82
Random Forest	0.9001	0.90	0.90	0.90
Support Vector Machine	0.9321	0.93	0.93	0.93
Ensemble Classifier	0.9405	0.94	0.94	0.94
Deep Learning Classifier				
CNN	0.98	0.98	0.98	0.98

این مقایسه به وضوح برتری مطلق رویکرد یادگیری عمیق را نشان می‌دهد. مدل CNN توانسته است با اختلاف قابل توجهی نسبت به بهترین مدل Ensemble، عملکرد بهتری از خود به نمایش بگذارد. دلیل اصلی این برتری، توانایی CNN در یادگیری ویژگی‌های پیچیده و معنادار به صورت خودکار و سلسله‌مراتبی از داده‌های خام تصویری است. در حالی که روش‌های کلاسیک به ویژگی‌های دست‌ساز شده مانند HOG محدود هستند که ممکن است نتوانند تمام تفاوت‌های ظریف بین کلاس‌های مختلف را به خوبی ثبت کنند.

نتیجه‌گیری

در این پروژه، یک مطالعه جامع برای طبقه‌بندی چندکلاسی تومورهای مغزی با استفاده از تصاویر MRI انجام شد. دو رویکرد اصلی شامل مدل‌های کلاسیک یادگیری ماشین با استخراج ویژگی دستی و یک مدل یادگیری عمیق از نوع CNN پیاده‌سازی و ارزیابی شدند. نتایج به دست آمده به طور قاطع نشان داد که مدل CNN با دقت ۹۷.۷۱ درصد به طور قابل توجهی از بهترین مدل کلاسیک یعنی Ensemble Classifier با دقت ۹۴.۰۵ درصد بهتر عمل می‌کند. این برتری نشان‌دهنده قدرت شبکه‌های عصبی عمیق در تحلیل تصاویر پزشکی و استخراج خودکار ویژگی‌های پیچیده است.

[1]

"Brain Tumor MRI Dataset." Accessed: Jul. 05, 2025. [Online]. Available: <https://www.kaggle.com/datasets/masoudnickparvar/brain-tumor-mri-dataset>